

Analisis Preprocessing Text Mining Menggunakan Orange

Nama Anggota:

- 1. Agus Dwijayanto**
- 2. Rizal Suryawan**
- 3. Siti Bastiani**

Judul

Analisis Preprocessing Dataset MTSamples Menggunakan Orange Data Mining

1. Dataset yang Digunakan

- **Nama Dataset**
MTSamples
- **Sumber Dataset**
Dataset bawaan pada aplikasi Orange Data Mining.
- **Deskripsi Dataset**
Dataset MTSamples merupakan kumpulan transkrip medis berbahasa Inggris yang berisi informasi mengenai diagnosis, pemeriksaan pasien, tindakan medis, operasi, dan riwayat kesehatan pasien.

Dataset ini banyak digunakan dalam text mining karena memiliki:

- a) jumlah dokumen yang besar,
- b) istilah medis yang beragam,
- c) struktur teks yang realistis.


2. Tujuan Analisis

Tujuan analisis preprocessing text mining pada dataset MTSamples adalah:

- 1) Membersihkan data teks dari simbol, angka, dan kata yang tidak penting.
- 2) Mengubah teks menjadi format yang lebih mudah dianalisis.
- 3) Menampilkan visualisasi kata yang paling sering muncul.
- 4) Mengidentifikasi topik utama yang terdapat dalam dataset medis.
- 5) Mempermudah proses text mining dan analisis data.

3. Workflow Orange

Workflow yang Digunakan:



Penjelasan workflow:

- Datasets digunakan untuk mengambil dataset bawaan Orange.
- Corpus digunakan untuk mengubah data menjadi format teks.
- Preprocess Text digunakan untuk membersihkan teks.
- Corpus Viewer digunakan untuk melihat hasil preprocessing.
- Word Cloud digunakan untuk visualisasi kata.
- Topic Modeling digunakan untuk menemukan topik utama.

4. Tahapan Workflow dan Penjelasanannya

1) Widget Datasets

The screenshot shows the 'Datasets - Orange' window. It features a search bar and a table of available datasets. The 'mtsamples' dataset is selected and highlighted. Below the table, a description of the 'mtsamples' dataset is provided.

Title	Size	Instances	Variables	Target	Tags
Banking Crises	31.3 KB	211	73	none	time, economy
SentiNews	5.0 MB	2000	8	categorical	text, sentiment
ParlaMint	1.7 MB	1000	18	categorical	text, classification, time, politics
BBC3	2.6 MB	1407	3	categorical	text, classification, news
mtsamples	3.3 MB	950	5	categorical	text, classification, medical
Food Words	10.1 KB	108	2	categorical	synthetic, text
English Words	10.6 KB	150	1	none	synthetic, text
Grades for English and ...	265 bytes	12	3	none	synthetic, educational
Course Grades	9.2 KB	16	8	none	synthetic, education
Car Evaluation	50.7 KB	1728	7	categorical	synthetic
MONK's 1	12.4 KB	556	7	categorical	synthetic

Description
mtsamples (2023), from <https://mtsamples.com/>
A sample of 950 medical transcriptions from three categories (from the original 40) -- Cardiovascular/Pulmonary, Neurology, and Orthopedic. Each document is a transcription of a medical report. Each document is equipped with keywords for potential keyword analysis.


Fungsi : Widget Datasets digunakan untuk memilih dataset bawaan dari Orange.

Dataset yang Dipilih : MTSamples

Pada tahap ini dipilih dataset MTSamples yang berisi transkrip medis. Dataset ini digunakan sebagai sumber data untuk proses text mining.

2) Widget Corpus

Fungsi : Widget Corpus digunakan untuk mengubah dataset menjadi format corpus agar dapat diproses pada text mining.



Tahap Corpus digunakan untuk membaca data teks dan mengubahnya menjadi corpus sehingga dapat diproses pada tahapan preprocessing dan analisis selanjutnya.


3) Widget Preprocess Text

Fungsi : Membersihkan dan mempersiapkan data teks sebelum dianalisis.

Setting yang Digunakan :

- Tokenization
 - Regexp
 - Pattern: \\w+
- Normalization
 - WordNet Lemmatizer
- Filtering
 - Stopwords: English

➤ Numbers: aktif




Pada tahap preprocessing dilakukan pembersihan teks menggunakan tokenization, lemmatization, dan filtering.

Tokenization digunakan untuk memecah teks menjadi kata-kata. Lemmatization digunakan untuk mengubah kata ke bentuk dasar. Filtering digunakan untuk menghapus stopwords dan angka sehingga data menjadi lebih bersih.

4) Widget Corpus Viewer

Fungsi : Menampilkan hasil preprocessing dan isi dokumen.



Corpus Viewer digunakan untuk melihat hasil preprocessing pada dokumen teks. Pada tahap ini dapat dilihat bahwa simbol dan angka sudah berhasil dibersihkan.

5) Widget Word Cloud

Fungsi : Menampilkan visualisasi kata yang paling sering muncul.

Hasil Visualisasi

Kata yang paling sering muncul antara lain:

patient


artery

diagnosis

procedure

pain

history



Word Cloud menunjukkan kata-kata yang paling sering muncul pada dataset. Semakin besar ukuran kata maka semakin sering kata tersebut muncul.

Hasil visualisasi menunjukkan bahwa dataset didominasi oleh istilah medis dan prosedur kesehatan.

6) Widget Topic Modeling

Fungsi : Mengelompokkan dokumen berdasarkan topik yang memiliki kemiripan kata.

Metode yang Digunakan : Latent Dirichlet Allocation (LDA)

Jumlah Topic : 10 topic

- Topic 1

patient, pain, nerve, muscle, examination, tendon

Topik ini berkaitan dengan pemeriksaan otot dan saraf.

- Topic 6


artery, coronary, pulmonary, catheter, cardiac

Topik ini berkaitan dengan prosedur kardiovaskular.

- Topic 8

spine, disc, canal, l4, l5, s1

Topik ini berkaitan dengan gangguan tulang belakang.



Topic Modeling digunakan untuk menemukan tema utama dalam dataset.

Hasil analisis menunjukkan bahwa dataset memiliki beberapa kelompok topik medis seperti:

- prosedur jantung,
- operasi ortopedi,
- gangguan tulang belakang,
- pemeriksaan pasien.

5. Analisis Hasil Preprocessing

Hasil Preprocessing

Setelah preprocessing dilakukan:

- tanda baca berhasil dihilangkan,
- angka berhasil dihapus,
- kata tidak penting berhasil dibersihkan,
- teks menjadi lebih rapi dan siap dianalisis.

Analisis Word Cloud

Word Cloud menunjukkan bahwa kata yang paling dominan adalah:

- patient,
- procedure,

- artery,
- diagnosis,
- pain.

Hal ini menunjukkan bahwa dataset didominasi oleh laporan medis, tindakan operasi, dan diagnosis pasien.

Analisis Topic Modeling

Topic Modeling menunjukkan bahwa dataset memiliki beberapa tema utama, yaitu:

- prosedur kardiovaskular,
- pemeriksaan klinis,
- operasi ortopedi,
- gangguan tulang belakang.

Hal ini membuktikan bahwa dataset MTSamples memiliki variasi topik medis yang cukup luas.

6. Kesimpulan

Berdasarkan hasil preprocessing dan visualisasi menggunakan Orange Data Mining dapat disimpulkan bahwa:

- 1) Preprocessing berhasil membersihkan data teks dari noise seperti simbol dan angka.
- 2) Word Cloud berhasil menampilkan kata-kata dominan dalam dataset.
- 3) Topic Modeling berhasil mengelompokkan dataset ke beberapa tema medis.
- 4) Dataset MTSamples cocok digunakan untuk analisis text mining karena memiliki banyak istilah medis dan variasi topik.
- 5) Orange Data Mining mempermudah proses preprocessing dan visualisasi data teks secara visual dan interaktif.